

摘要

植物的种类繁多，为研究植物分类方法，本文基于植物树叶的二值化图片数据，通过解析几何计算和时间序列展开的方法转换成轮廓特征向量和边缘特征向量；再通过粒子群算法优化的深度神经网络解决树叶识别分类问题，并分析核心指标对模型性能的影响，最终结合树叶纹理信息对模型进行改进和分析比较。

针对问题一，通过解析几何计算和时间序列展开，分别提取每一张图片中的特征向量。根据题目要求，本组首先利用 **matlab** 计算与图像形状相关的解析几何特征量，得到由八个几何学、拓扑学特征值组成的八维形状特征向量。然后将图像轮廓进行极化投影，并通过 **numpy** 工具箱将极化投影轮廓展开成时间序列，挖掘分析时间序列的三个特征值，组成三维边缘特征向量。最后合并两个向量得到十一维总体特征向量。

针对问题二，基于问题一中提取的特征信息，建立了 **PSO-DNN 网络** 对树叶进行识别与分类。利用 **Keras** 工具库搭建深度神经网络，利用粒子群算法优化 DNN 网络的连接权值和阈值，对研究对象进行识别分类。训练后的神经网络模型预测准确率为 **91.037%**，并分析各指标的权重占比，判断出特征量中时间序列熵、密实度和最大压痕深度对模型性能影响最大，是模型的核心指标。将其剔除后，模型分类精确度损失率分别为 **6.937%**、**5.498%**、**3.559%**。

针对问题三，基于问题二中的 **PSO-DNN 网络** 模型，将树叶纹理信息嵌入特征向量。增加网络输入层个数，并对模型进行参数调整，最终得到叶片的预测准确率达到 **96.634%**。

本文中所提到的模型优点主要有两点：一、提取的特征值信息包含量大、区分度高；二、利用 PSO 优化后的 DNN 网络全局收敛能力强，分类准确度高。

关键词： 时间序列展开 深度神经网络 粒子群算法 **Keras** 工具库

目录

一、 问题重述	4
1.1 问题背景	4
1.2 问题概述	4
二、 模型假设	4
三、 符号说明	5
四、 问题一模型的建立与求解	6
4.1 问题描述与分析	6
4.2 模型的建立	6
4.2.1 预备工作	6
4.2.2 优化函数与约束条件	7
4.3 模型的求解	8
4.3.1 沙石算法	8
4.4 结果分析	10
五、 问题二模型的建立与求解	10
5.1 问题的描述与分析	10
5.2 模型的建立与求解	10
5.2.1 DNN 网络搭建	10
5.2.2 PSO 优化 DNN 网络	13
5.2.3 参数的选取与确定	14
5.3 实验与结果分析	14
5.3.1 模型性能评估	16
六、 问题三模型的建立与求解	17
6.1 问题描述与分析	17
6.2 模型的建立与求解	17
6.3 结果分析	18
七、 模型的评价	19
7.1 模型的优点	19
7.2 模型的缺点	19

附录 A 代码	21
A.1 图片名称读取—matlab 源代码	21

一、问题重述

1.1 问题背景

诺曼底登陆：代号“霸王行动”，是第二次世界大战中盟军在欧洲西线战场发起的一场大规模攻势，接近三百万士兵渡过英吉利海峡前往法国诺曼底。诺曼底战役是人类战争史上规模最大的一次海上登陆战役行动，使第二次世界大战的战略态势发生了根本性的变化。

海运装载是海上登陆战役中的一种作战行动，将需要登陆的部队人员、装备、补给品装载到海上运输工具，该行动会直接影响着登陆作战效果。以诺曼底战役的第一批海上登陆输送兵力为参考，不同成建制单位的部队人员、装备和补给品都有不同的数量级需求，研究合理利用海军运输船和民用船只进行兵力装载以及对装载方案的优化都具有重要意义。

1.2 问题概述

围绕相关附件和条件要求，研究海运装载行动输送兵力任务的合理安排，依次提出以下问题：

问题一：根据输送任务和海上运输工具情况，结合相关条件和要求，分析运输船舰和兵力的关系，概算各类型旅一个旅级单位的运输工具的需求量，并给出具体装载方案。

问题二：根据输送任务，结合附件中的港口及码头泊位，制定时间最短、船只数量最少的兵力装载方案。

问题三：假设装载行动开始 24 小时后，A 港口的两个 A1 和一个 A2 泊位，D 港口的一个 D2 和两个 D3 泊位被毁，给出具体调整方案以及完成装载任务的对策建议。

二、模型假设

- (1) 为了简化计算，假设题目中给出的模糊数据都是精确数据。
- (2) 为了优化运算结果，假设所有全副武装的士兵都保持坐姿休息。
- (3) 假设在战争中，装载消耗更少时间的优先度高于使用更少的民用船。
- (4) 假设在装载过程中，同一泊口的船舰装载交替时间可以忽略不计。
- (5) 假设港口被摧毁时，由于提前得到信息，港口上的船只与兵力没有损失，只是正在进行的装载工作停止，且进度完全损失。

三、符号说明

符号	说明
I	研究图像
$A(I)$	图像面积
$C(I)$	图像几何中心
∂I	图像边界
$d(.)$	运算两点间欧式距离
ID	总特征向量
ID_{shape}	形状特征向量
ID_{margin}	边缘特征向量
id_k	研究图像特征值
r	极径
θ	极角
X	时间序列集
S	shapelet 子序列
x_i	神经网络第 i 个输入值
w_{ki}	第 i 个输入量连接的权值
b_k	神经网络阈值
f	激活函数
e	误差函数
E	全局误差
η	学习率
$c_{1,2}$	加速因子
β	惯性权重

四、问题一模型的建立与求解

4.1 问题描述与分析

问题一要求根据输送任务和船舰情况分析运输船舰和兵力的关系，概算各类型旅一个旅级单位对船舰的需求量与装载方案。其本质是一个**多背包优化问题**：要求使用尽可能少的背包，装载各种旅的一个旅编制兵力。根据题目要求，以派出船舰种类和数量作为决策向量，以所用的总船只数量为目标函数，以每艘船的面积装载限制作为约束条件。通过本组设计的**沙石算法**，使得每艘船面积利用率达到最高，从而使得调用船支数达到最小值，并给出其装载方案。其沙石算法示意图如图 1 所示：




图 1 沙石算法示意图

4.2 模型的建立

4.2.1 预备工作

兵力、装备与船载的面积量化 计算附件 2 中的每种装备与所占面积：

$$s_{xi} = l_i \times w_i \times \varepsilon_i$$

其中 s_{xi} 是装备 $X_i (i = 1, 2, \dots, 14)$ 的占用面积， l_i 、 w_i 与 ε_i 分别是装备 X_i 的长、宽与面积修正系数。得到装备占用面积向量：

$$S_x = [s_{x1}, s_{x2}, \dots, s_{x14}] \quad (1)$$

计算附件 2 中每种旅一个营的占用面积：

$$s_{pi} = p_i \times s$$

其中 p_i 是第 $i (i = 1, 2, \dots, 12)$ 的全副武装人员数，取 $s = 0.5m^2$ 为每个全副武装人员占用的面积。得到每营人口所占面积向量：

$$S_p = [s_{p1}, s_{p2}, \dots, s_{p12}] \quad (2)$$

计算附件 3 中船舰可用装载面积：

$$s_{yi} = s_i \times \eta_1 \quad (3)$$

其中 s_{yi} 是登陆舰 $Y_i (i = 1, 2 \cdots, 14)$ 的可用装载面积， s_i 是登陆舰 Y_i 的总装载面积，取 $\eta_1 = 75\%$ 为登陆舰的有效面积率。得到登陆舰有效面积向量：

$$S_y = [s_{y1}, s_{y2}, \cdots, s_{y14}] \quad (4)$$

$$s_{zj} = s_j \times \eta_2 \quad (5)$$

其中 s_{zj} 民用船 $Z_j (i = 1, 2 \cdots, 5)$ 的可用装载面积， s_j 是民用船 Z_j 的总装载面积，取 $\eta_2 = 70\%$ 为登陆舰的有效面积率。得到登陆舰有效面积向量：

$$S_z = [s_{z1}, s_{z2}, \cdots, s_{z5}] \quad (6)$$

4.2.2 优化函数与约束条件

决策向量为：

$$D = [y_1, y_2, \cdots, y_{14}, z_1, z_2, \cdots, z_5] \quad (7)$$

其中 y_k 是派出的登陆舰数量， z_k 是派出民用船的数量。

根据题意尽可能使用少的船舰数，即**目标函数**为使用船舰总数：

$$\min Z = \sum D \quad (8)$$

舰载面积系数向量为：

$$S_D = [S_y, S_z] \quad (9)$$

根据题目要求总舰载有效面积不小于总兵力装备占用面积：

$$D \cdot S_D \geq \sum S_x + \sum S_p \quad (10)$$

且由登陆舰 Y1 的有效舰载面积大于装备 X9(直升机) 的部队占用的面积：

$$y_1 \cdot s_{y1} \geq \sum s_{x9} + \sum s_{p6} \quad (11)$$

其中 $\sum s_{p6}$ 是唯一装备的部队——VI 旅的人口总和。

建立得到使用最少船舰装载每种旅各一个旅级编制的模型为：

$$\begin{aligned} \min Z &= \sum D & (12) \\ \text{s.t.} \left\{ \begin{array}{l} D \cdot S_D \geq \sum S_x + \sum S_p \\ y_1 \cdot s_{y1} \geq \sum s_{x9} + \sum s_{p6} \\ S_D = [S_y, S_z] \\ s_{xi} = l_i \times w_i \times \varepsilon_i \\ S_x = [s_{x1}, s_{x2}, \dots, s_{x14}] \\ s_{pi} = p_i \times s \\ S_p = [s_{p1}, s_{p2}, \dots, s_{p12}] \\ s_{yi} = s_i \times \eta_1 \\ S_y = [s_{y1}, s_{y2}, \dots, s_{y14}] \\ s_{zj} = s_j \times \eta_2 \\ S_z = [s_{z1}, s_{z2}, \dots, s_{z5}] \end{array} \right. & (13) \end{aligned}$$

4.3 模型的求解

4.3.1 沙石算法

为使得调用的船舰数量最少，即需使得每艘船的未利用面积值达到最小：

$$\min \Delta S = \sum S_x + \sum S_p - D \cdot S_D \quad (14)$$

其中 ΔS 为损失面积，本组设计沙石算法优化部队装载方案，使其得面积损失达到最小，具体如下：

算法思想 根据经验，使用沙砾和石子填满某个刚性容器，较好的方法是先装入石子，后灌入沙砾，可以让剩余空间达到最小。基于此，本组设计沙石算法，将待待装载部队(其占用面积不尽相同)视作沙砾与石子，将船舰视作刚性容器，即可求出面积利用率最高的部队装载方案。

算法描述

(1) 装备均分：将每个旅分解为连编制，即得到面积规划向量：

$$A^k = [a_1^k, a_2^k, \dots, a_n^k] \quad (15)$$

其中 a_i^k 的初始值是第 k 旅中的全副武装人员所占面积，其中 $k = 1, 2, \dots, K$ (K 为旅队编制总数)， $n = n_k$ (n_k 为 k 旅连编制总数)。根据题目中装备均匀分配的要求，

重复检索向量 A^k 中的每一个元素，选择最小值 $\min \{a_i\}$ (装备量最少的营) 使得该连添加装备 X_j , 即令:

$$\min \{a_i\} = \min \{a_i\} + s_{xj} \quad (16)$$

重复检索直到该旅装备数 $X = 0$ 时, 结束装备均分, 得到装备均分后的部队 $\{A^k\}$ ($k = 1, 2, \dots, n_k$) (n_k 为 k 旅连编制总数)。

- (2) 部队装载: 将装备均分后的部队 $\{A^k\}$ 中的元素混合后由大到小进行排序得到排序后的营编制总部对数列 $\{T_n\}$:

$$T_n \geq T_{n+1} \quad (17)$$

$$n \leq \sum_1^K n_k \quad (18)$$

将所有派出船舰装载面积进行排序得到船舰面积数列 $\{P_n\}$:

$$P_n \geq P_{n+1}$$

$$n \leq \sum D$$

依次检索总部对数列 $\{T_n\}$, 并依次检索数列 $\{P_n\}$ 对应的船舰, 将其装入剩余面积足够的船舰, 即若 $P_n \geq T_n$ 令:

$$P_n = P_n - T_n$$

重复检索直到部队装载完成, 即当部队检索次数 $i = \sum_1^K n_k$ 时, 算法结束。

- (3) 结果输出: 输出总共使用的船舰数量, 即决策向量:

$$D = [y_1, y_2, \dots, y_{14}, z_1, z_2, \dots, z_5]$$

4.4 结果分析

表 1 各旅级单位装备人口面积装载方案

船舰类别	第 I 型旅	第 II 型旅	第 XI 型旅	第 XII 型 支队（旅）
Y1 综合登陆舰	267.6285185	0	5658.770914	42.85714286
Y2 大型登陆舰	1586.951111	0	0	0
Y3 大型登陆舰	3178.042222	0	5864.014286	0
Y4 大型登陆舰	2114.508148	0	0	0
‘.....
Y12 登陆艇	0	0	0	728.5714286
Y13 登陆艇	0	0	0	0
Y14 登陆艇	0	0	0	0
2 万吨级滚装船	0	6549.897037	0	0

五、 问题二模型的建立与求解

5.1 问题的描述与分析

5.2 模型的建立与求解

5.2.1 DNN 网络搭建

DNN 的正向传播主要依靠众多神经元的计算来完成的，此处设计的网络结构如图 2 所示，工作过程中可以用下式来表示：

$$u_k = \sum_{i=1} w_{ki} x_i$$

(19)

$$y_k = f(u_k - b_k)$$

(20)

其中: x_i 表示第 i 个输入; w_{ki} 表示与第 i 输入量相连的权值; u_k 表示所有输入的加权和; b_k 为神经元阈值; f 为激活函数; y_k 为神经网络的输出。

激活函数的种类有很多，如 *sigmoid*, *tanh* 及 *Relu*，本文应用的是 *Relu* 作为激活

函数搭建两层隐含层，如式 21 所示：

$$\begin{aligned} f_{\text{Relu}} &= \max(0, z) \\ \frac{d}{dz} f_{\text{ReLU}} &= \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases} \end{aligned} \quad (21)$$

网络的输出层使用 *softmax* 函数作分类器，式 22 为第 i 个神经的输出：

$$f_{\text{softmax}} = e^i / \sum_j e^j \quad (22)$$

具体算法步骤如下：

- (1) 进行网络的初始化设置，用 $(-1, 1)$ 之间的随机数对 DNN 各个层的权值和阈值分别进行相应初始化，设定误差函数为 e 、计算精度为 ϵ 、学习速率为 η 以及最大学习次数为 M 。
- (2) 随机选取第 k 次输入样本 $x(k)$ 以及对应的实际期望输出 $d(k)$ 如下：

$$\begin{aligned} x(k) &= [x_1(k), x_2(k), \dots, x_n(k)] \\ d(k) &= [d_1(k), d_2(k), \dots, d_r(k)] \end{aligned}$$

- (3) 计算 DNN 中第 1 隐含层、第 2 隐含层以及输出层的输入值和输出值具体计算公式如下：

$$\begin{aligned} h_{bs}(k) &= \sum_{i=1}^n u_{is} x_i(k) + b_s \quad s = 1, 2, \dots, p \\ h_{os}(k) &= f_1(h_{bs}(k)) \quad s = 1, 2, \dots, p \\ g_{bt}(k) &= \sum_{s=1}^p v_{st} h_{os}(k) + b_t \quad t = 1, 2, \dots, q \\ g_{ot}(k) &= f_2(g_{bt}(k)) \quad s = 1, 2, \dots, q \\ y_{bj}(k) &= \sum_{i=1}^q w_{ij} g_{at}(k) + b_j \quad j = 1, 2, \dots, r \\ y_{oj}(k) &= f_3(y_{bj}(k)) \quad j = 1, 2, \dots, r \end{aligned}$$

其中 x_i 输入层输入向量, h_b 为第 1 隐含层输入向量, h_o 为第 1 隐含层输出向量, g_b 为第 2 隐含层输入向量, g_o 为第 2 隐含层输出向量, y_b 为输出层输入向量, y_o 为输出层输出向量

- (4) 首先给定误差函数如下：

$$e = \frac{1}{2} \sum_{j=1}^r (d_j(k) - y_{bj}(k))^2$$

误差函数 e 对输出各层求偏导数得：

$$\begin{aligned}\frac{\partial e}{\partial y_{bj}(k)} &= \delta_j(k) \\ \frac{\partial e}{\partial g_{bt}(k)} &= \delta_t(k) \\ \frac{\partial e}{\partial h_{bs}}(k) &= \delta_s(k)\end{aligned}$$

即通过 δ 值与各层的输出修正各层级间的权值, 其计算公式如下：

$$\begin{aligned}w_{tj}^{N+1} &= w_{tj}^N + \eta \delta_j(k) g_{ot}(k) \\ w_{st}^{N+1} &= w_{st}^N + \eta \delta_t(k) g_{os}(k) \\ w_{is}^{N+1} &= w_{is}^N + \eta \delta_j(k) g_{ot}(k)\end{aligned}$$

同理，各层级阈值变化公式如下

$$\begin{aligned}\Delta b_j(k) &= \eta \delta_j(k) \\ \Delta b_t(k) &= \eta \delta_t(k) \\ \Delta b_s(k) &= \eta \delta_s(k)\end{aligned}$$

使用当前权值计算全局误差，公式如下：

$$E = \frac{1}{2m} \sum_{k=1}^m \sum_{j=1}^r (d_j(k) - y_{oj}(k))^2$$

当误差小于预设精度 ε 或达到最大学习次数 M 时网络算法结束, 否则返回 (2) 进行下一轮学习训练.




图 2 人工搭建 DNN 结构示意图

5.2.2 PSO 优化 DNN 网络

算法的具体实现步骤如下：

- (1) 将 DNN 网络结构中所有神经元间的连接权值和各个神经元的阈值编码成实数码串表示的个体作为 PSO 算法要寻优的位置向量。
- (2) 在编码空间中随机生成一定数目的个体组成种群，其不同个体代表神经网络不同权值。
- (3) DNN 网络训练及个体的适应度评价。将微粒群中的每一个个体的分量映射为网络中的权值和阈值，从而构成个体对应的神经网络。首先划分训练样本和测试样本；其次输入训练样本进行网络训练，通过反复迭代来优化网络权值，并计算每一个网络在训练集上产生的均方误差，以此作为目标函数；最后对每个个体进行适应度评价，从中找到最佳个体用来判断是否需要更新微粒的 Gbest 与 Pbest，以全局误差值作为适应度函数：

$$E = \frac{1}{2m} \sum_{k=1}^m \sum_{j=1}^r (d_j(k) - y_{oj}(k))^2$$

式中： m 为训练样本个数， r 为输出端个数， $y_{oj}(k)$ 为训练样本在输出端的给定输出， $d_j(k)$ 为训练样本在输出端的实测值，他们俩个值的误差平方和越小，表示实际值和预测值越接近，网络的性能越好。

(4) 更新每个粒子的速度和位置，产生下一代的粒子群。更新公式如下：

$$v_{id}^{t+1} = v_{id}^t + c_1 r_1 (p_{id}^t - x_{id}^t) + c_2 r_2 (g_{id}^t - x_{id}^t) \quad (23)$$

$$x_{id}^{t+1} = x_{id}^t + v_{id}^{t+1} \quad (24)$$

其中 $i = 1, 2, \dots, n; d = 1, 2, \dots, d; t$ 为当前迭代次数; v_{id}^t 为当前粒子速度 (t 时刻); x_{id}^t 为当前粒子位置 (t 时刻); $(p_{id}^t - x_{id}^t)$ 为当前位置与自己最好位置之间的距离; $(g_{id}^t - x_{id}^t)$ 为当前位置与群体最好位置之间的距离; v_{id}^{t+1} 为下一时刻粒子速度 ($t+1$ 时刻); c_1, c_2 为非负常数，称为加速因子; r_1, r_2 为均匀分布与 $[0, 1]$ 区间的随机数。

(5) 当目标函数小于给定的误差或达到最大迭代次数时，算法结束。将 PSO 算法训练出来的最佳神经网络的权值和阈值作为 DNN 网络的初始值，并记录计算指标重要度：

$$Ipot(k) = \sum |w_{tj}(k)| \quad (25)$$

其中 $w_{tj}(k)$ 为特征值 id_k 训练后的输入权重。

5.2.3 参数的选取与确定

由于训练 epochs 与步长选取较为困难，实验采取**网格搜索法**（Grid Search）来确定参数的选取，网格搜索是指定参数值的一种穷举搜索方法，通过将估计函数的参数通过交叉验证的方法进行优化来得到最优的学习算法。

在迭代修正的过程中，实验采用 *Keras* 自带优化器 **Adam 函数** 进行迭代修正，如式 5.2.3 所示，其中 β_1 一般取 0.9， β_2 一般取 0.999。

$$\begin{cases} m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_w f(w_t) \\ v_t = \beta_2 v_{t-1} + (1 - \beta_2) \nabla_w f(w_t)^2 \\ \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \\ w_t = w_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}} \end{cases}$$

5.3 实验与结果分析

随机选取 80% 的数据作为训练集进行**数据标准化处理**，再对树叶种类（species）进行 **One-Hot 编码** 作为分类目标。训练输入样本为 $1280 * 11$ ，测试输入样本为 $320 * 11$ ，DNN 网络输入层神经元 11 个，输出层神经元 100 个，包含 2 个隐含层，适应度函数选择均方误差。按照 PSO 优化 DNN 网络模型的步骤不断地迭代寻找最优网络参数，进行树叶分类预测的仿真实验。具体参数设置见表 ??。

表 2 各旅级单位装载方案

舰船类别	第 I 型旅	第 II 型旅	第 XI 型旅	第 XII 型 支队（旅）
Y1 综合登陆舰	267.6285185	0	5658.770914	42.85714286
Y2 大型登陆舰	1586.951111	0	0	0
Y3 大型登陆舰	3178.042222	0	5864.014286	0
.....
Y12 登陆艇	0	0	0	728.5714286
Y13 登陆艇	0	0	0	0
Y14 登陆艇	0	0	0	0
2 万吨级滚装船	0	6549.897037	0	0

通过上述参数设置，计算训练后各指标指标重要度，将指标重要度求和，计算每个指标重要度占权得到 4，最小均方误差为 0.458，预测准确率为 91.037%。其迭代过程中损失与准确率如下图所示：




图 3 PSO-DNN 迭代过程中损失与准确率

各指标所占权重占比




图 4 指标重要度占权图

由图 4 可知各指标对模型判别性能的影响，选取重要度占比最高的三个指标——时间序列熵，密实度，最大压痕深度作为核心指标。分别剔除三个指标，再次进行训练与预测，得到缺失核心指标的模型性能如下：

表 3 缺失核心指标的模型性能

缺失指标	分类准确度	精度损失率
时间序列熵	84.721%	6.937%
密实度	86.112%	5.498%
最大压痕深度	87.538%	3.559%

5.3.1 模型性能评估

表 4 中，实验与三种神经网络进行纵向比较可知，四种神经网络训练后准确率都在 90% 左右，证实了神经网络非线性映射能力较强。Elman 网络和 DNN 网络的测试准确率都大于 BP 网络，说明反馈动态网络的逼近能力要强于前反馈静态网络。使用 PSO 优化 DNN 网络后，模型的跟踪性能有所改善，测试集中损失 (Validation Loss) 仅为 0.458，

说明 PSO-DNN 网络的泛化能力和稳定性明显提高，且全局收敛性增强。

表 4 常见神经网络的比较

网络类型	网络名称	测试集中准确率
静态网络	BP	87.424%
静态网络	Elman	90.541%
动态网络	DNN	89.912%
动态网络	PSO-DNN	91.037%

六、问题三模型的建立与求解

6.1 问题描述与分析

针对问题三，本题要求结合给出的叶子纹理的数据信息，对问题二原有模型进行改进并进行分析比较。本组基于问题二模型中原有的 11 维数据，加入叶子纹理的数据信息后增加网络输入层个数，修改 PSO-DNN 网络的参数，从而提高了叶片识别与分类的精度。

6.2 模型的建立与求解

加入叶片纹理数据后，根据第二问中模型原理进行参数调整，进行树叶分类预测的仿真实验：随机选取 80% 的数据作为训练集进行数据**标准化处理**，再对树叶种类进行**One-Hot 编码**作为分类目标。训练输入样本为 1280×75 ，测试输入样本为 320×75 ，DNN 网络输入层神经元 75 个，输出层神经元 100 个，包含 2 个隐含层，适应度函数选择均方误差。具体参数设置见表 5。具体参数：

表 5 参数设置表

参数名称	参数符号	参数值
选择粒子个数为	T	30
计算精度	ε	0.00001
学习率	η	0.01
最大迭代次数	M	500
维度	S	75
加速因子 1	c_1	1.49
加速因子 2	c_2	1.49
惯性权重	β	0.9

通过上述参数设置，训练后求得最小均方误差为 0.253，预测准确率为 96.634%，其迭代过程中损失与准确率如下图所示：




图 5 PSO-DNN 迭代过程中损失与准确率

6.3 结果分析

分别与问题二中的 PSO 优化前后 DNN 模型进行比较，其结果如下所示：

表 6 新旧 PSO-DNN 网络的比较

网络模型	Validation Loss	Validation Accuracy
新 PSO-DNN 网络	0.253	96.634%
旧 PSO-DNN 网络	0.458	91.037%
新 DNN 网络	0.291	95.142%
旧 DNN 网络	0.518	89.912%

结果表明，问题三的 PSO-DNN 网络在测试集中准确率高于问题二中网络，说明在加入叶子纹理数据后，其分类模型预测能力升高，符合实际情况。与未经过 PSO 优化权值的网络比较均提升 1% 左右，证实了 PSO-DNN 网络非线性映射能力较强。

七、模型的评价

7.1 模型的优点

- (1) 利用时间序列提取树叶边缘信息，相较于传统特征量能更准确直观的表述边缘特征。
- (2) PSO 优化后的 DNN 网络非线性映射能力强，泛化能力和稳定性明显高于一般神经网络，具有更强的鲁棒性。其全局收敛能力强，预测准确度高。

7.2 模型的缺点

树叶二值化图片信息提取不够完全，若能提取更高维度特征向量，分类准确度可进一步提高。

参考文献

- [1] Tan Jing Wei, Chang Siow-Wee, Binti Abdul Kareem Sameem, Yap Hwa Jen, Yong Kien-Thai. Deep Learning for Plant Species Classification using Leaf Vein Morphometric.[J]. IEEE/ACM transactions on computational biology and bioinformatics, 2018.
- [2] Liu Jing, Sun Wanning, Su Yuting, Jing Peiguang, Yang Xiaokang. BE-CALF: Bit-Depth Enhancement by Concatenating All Level Features of DNN.[J]. IEEE transactions on image processing : a publication of the IEEE Signal Processing Society, 2019, 28(10).
- [3] Matheus B. Vicari, Mathias Disney, Phil Wilkes, Andrew Burt, Kim Calders, William Woodgate. Leaf and wood classification framework for terrestrial LiDAR point clouds[J]. Methods in Ecology and Evolution, 2019, 10(5).
- [4] 田德红, 何建敏. 基于变异粒子群优化与深度神经网络的航空弹药消耗预测模型 [J]. 南京理工大学学报, 2018, 42(06).
- [5] 原继东, 王志海, 韩萌, 游洋. 基于逻辑 shapelets 转换的时间序列分类算法 [J]. 计算机学报, 2015, 38(07):1448-1459.
- [6] 杨志辉, 胡红萍, 白艳萍. 基于主成分分析和 PSO-SVM 的树叶分类方法研究 [J]. 数学的实践与认识, 2016, 46(18):170-175.
- [7] 侯铜, 姚立红, 阚江明. 基于叶片外形特征的植物识别研究 [J]. 湖南农业科学, 2009(04):123-125+129.
- [8] Febri Liantoni, Rifki Indra Perwira, Syahri Muharom, Riza Agung Firmansyah, Akhmad Fahruzi. Leaf classification with improved image feature based on the seven moment invariant[J]. Journal of Physics: Conference Series, 2019, 1175(1).

附录 A 代码

A.1 图片名称读取-matlab 源代码
